





Retrieval Augmented Generation (RAG)

Generación aumentada por
recuperación



Problema de los LLMs Puros



1


- **Alucinaciones:** Los modelos generan respuestas que suenan coherentes pero son **factualmente falsas** debido a limitaciones estadísticas.

2

- **Conocimiento Estático:** Un LLM solo sabe lo que existía hasta su fecha de corte de entrenamiento (knowledge cutoff).


3

- **Falta de Privacidad:** No pueden acceder de forma nativa a datos privados, manuales internos o repositorios corporativos sin un costoso re-entrenamiento.




¿QUÉ ES RAG (GENERACIÓN AUMENTADA POR RECUPERACIÓN)?

La generación aumentada por recuperación (RAG) es una técnica transformadora en la IA generativa, particularmente en el procesamiento del lenguaje natural (PLN) y los sistemas de recomendación. Mejora la calidad del contenido al integrar información externa y actualizada proveniente de fuentes de conocimiento.



¿Cómo funciona RAG?



Se cargan los documentos

1

Se convierten en embeddings

2

Se dividen en fragmentos

3

Se guardan en una base vectorial

4

El usuario hace una pregunta

5


El sistema busca los fragmentos más relevantes

6

El modelo genera la respuesta

7

Componentes principales de RAG



1

Retriever

El retriever es el encargado de buscar la información relevante. Su trabajo es encontrar los fragmentos más relacionados con la pregunta del usuario.

2

Generator


El generator es el modelo de lenguaje que redacta la respuesta final. Puede ser un modelo como GPT, LLaMA, Gemini u otro LLM. Su función es tomar la pregunta y la información recuperada para producir una respuesta coherente.

3

Retrieval Fusion

La fusión de recuperación es la forma en que la información encontrada se combina con la pregunta del usuario.

Componentes Técnicos del "Retriever"



CHUNKING (FRAGMENTACIÓN):

- Estrategias para cortar documentos largos en piezas óptimas (ej. ventanas deslizantes de 512 tokens) para no saturar la memoria del modelo.


EMBEDDINGS (INCRUSTACIONES):

- Modelos encoder (como BERT o Ada de OpenAI) que transforman el texto a vectores matemáticos de alta dimensionalidad conservando su significado conceptual.

BÚSQUEDA VECTORIAL:

- Algoritmos como HNSW (Hierarchical Navigable Small World) que permiten indexar millones de vectores y hacer búsquedas de similitud de coseno en milisegundos.

La Evolución de los Paradigmas RAG



NAIVE RAG (RAG BÁSICO):

- El flujo tradicional y lineal (Indexar -> Recuperar -> Generar). Problemas: recupera mucha información irrelevante (ruido) o bloquea datos importantes.

ADVANCED RAG (RAG AVANZADO):

- Introduce técnicas de pre-recuperación (reescritura y expansión de la pregunta para buscar mejor) y post-recuperación (Re-ranking para ordenar los fragmentos de los más a los menos importantes antes de pasárselos al LLM).


MODULAR RAG (RAG MODULAR):

- El paradigma actual. Estructura descentralizada que añade módulos específicos como herramientas de búsqueda web, módulos de memoria a largo plazo y filtros de alineación.

Fundamento Matemático / Optimización


¿Cómo aprende el generador a priorizar esta información? Se optimiza mediante la función de Pérdida Logarítmica Negativa Condicionada (NLL).

$$\text{NLL} = - \sum_{t=1}^{|y|} \log P_G(y_t \mid x, m, y_{<t})$$



Evaluación del Sistema (El RAG Triad)

Puntos clave: Evaluar RAG es difícil porque hay muchas partes móviles. Se utiliza el concepto del "Triángulo de Evaluación":



Faithfulness (Fidelidad):

¿La respuesta generada por el LLM se basa únicamente en el contexto proporcionado?
(Detecta alucinaciones).

Answer Relevance (Relevancia de la Respuesta):


¿La respuesta realmente contesta la pregunta del usuario?

Context Relevance (Relevancia del Contexto):

¿El buscador recuperó información valiosa o trajo basura/ruido?

Herramientas actuales: Frameworks como Ragas o ARES que utilizan un LLM potente (como GPT-4) actuando como "juez" para calificar estas tres métricas automáticamente.

RAG vs. Fine-Tuning



RAG:

- Dinámica e instantánea (en tiempo real al cambiar los archivos de la base de datos).
- No altera el modelo (usa el LLM base tal como está).
- Alucinaciones mínimas (el modelo está obligado y condicionado matemáticamente a basarse en el contexto).
- Trazabilidad total
- Costo bajo (solo requiere costo de inferencia y almacenamiento vectorial).

VS

RAG

- Estática (requiere un nuevo proceso de entrenamiento para aprender nuevos datos).
- Altera al modelo
- Alucinaciones Moderadas/Altas (el modelo intenta memorizar datos en sus pesos internos y puede inventar detalles).
- Trazabilidad nula
- Costo alto (requiere GPUs para el entrenamiento del dataset).

USA RAG PARA ACCEDER A DATOS. * USA FINE-TUNING PARA APRENDER UN ESTILO O FORMATO.

El Futuro: Agentes RAG y Multi-modalidad

TENDENCIAS DE INVESTIGACIÓN ACTUAL:


CORRECTIVE RAG

(CRAG):


El sistema evalúa de forma autónoma si los documentos recuperados son buenos. Si nota que son de mala calidad, activa automáticamente una búsqueda en Google en tiempo real.

RAG MULTIMODAL:

Ya no solo se busca texto; las bases de datos vectoriales indexan imágenes, diagramas de ingeniería y videos, permitiendo al LLM responder preguntas visuales complejas del entorno operativo de una empresa.




Implementación Práctica



ARTICULOS

RETRIEVAL-AUGMENTED
GENERATION FOR LARGE
LANGUAGE MODELS: A
SURVEY



Gracias